Mini Project SQL

Analisa Keuntungan Perusahaan Berdasarkan Produk, Kota Pembeli, Biaya Logistik, dan Durasi Pengiriman

Ahmad Malik Ibrahim

Introduction



Self-Overview

Nama saya Ahmad Malik Ibrahim, saya adalah lulusan jurusan kedokteran yang memiliki minat tinggi pada statistic, analisis, dan matematika. Tujuan saya dalam karir adalah untuk mendapatkan pekerjaan sebagai data analis

Education

- Bachelor of Medicine – UIN Syarih Hidayatullah
- Medical Doctor – UIN Syarif Hidayatullah

Working Experience

1. Independent Logistics Partner (Feb 2020 – May 2025)
   At Gojek (Part-Time)
2. General Practitioner Intern (May 2025 – Jan 2026)
   at RSUD M. Zein Painan West Sumatra (Internship)
3. General Practitioner (Feb 2026 – Aug 2026)
   at Klinik Pratama Pinang Sari 2 (Contract)

Overview Project

Overview Project

Judul Project
Analisis Penyebab Tingginya Turnover Rate di Suatu Perusahaan
Tujuan

- Tipe karyawan yang banyak melakukan Turnover
- Departemen yang memiliki Turnover Rate tertinggi
  Hasil Penelitian
- Turnover Rate tertinggi terjadi di departemen Production. Jenis kelamin dan kategori usia yang turnover pada departemen tersebut adalah Perempuan Dewasa dengan performance Fully Meets. Mereka Mengundurkan Diri dengan title Production Technician, job function sebagai Laborer, dan divisi Field Operation

Overview Project

Judul Project
Analisa Keuntungan Perusahaan Berdasarkan Kategori Produk, Lokasi, dan Pelanggan
Tujuan

- Mengetahui kategori produk yang memberikan keuntungan terbesar bagi Perusahaan
- Mengetahui letak transaksi yang memberikan keuntungan terbesar bagi Perusahaan
- Mencari tahu tipe pelanggan tertentu yang memberi keuntungan besar bagi Perusahaan ?

Overview Project

Judul Project
Analisa Hubungan Penjualan dan Keuntungan Perusahaan
Tujuan

- Mengetahui apakah terdapat hubungan antara penjualan dan keuntungan perusahaan
- Mencari tahu faktor lain yang dapat mempengaruhi penjualan dan keuntungan perusahaan
- Mengetahui jenis barang yang berpotensi memberikan keuntungan dan kerugian bagi perusahaan

Main Project

Table of Content

1. Problem Statement
2. Data Understanding
   2.1. Data Exploration
   2.2. Insight Data Exploration
3. Data Preparation
   3.1. Data Cleaning
   3.2. Feature Engineering
4. EDA
5. Insight
6. Recommendation

1. Problem Statement

PROBLEM STATEMENT

Mendag Respons Ongkir Dibebankan Seller di E-Commerce: Masih Dibahas

Retno Ayuningrum - detikBali
Senin, 11 Mei 2026 08:25 WIB



Menteri Perdagangan (Mendag) Budi Santoso. Foto: Retno Ayuningrum

Denpasar - Menteri Perdagangan (Mendag) Budi Santoso merespons keluhan para penjual terkait pengenaan biaya logistik atau ongkos kirim (ongkir) oleh sejumlah platform e-commerce. Skema tersebut dinilai membebani seller karena biaya pengiriman dibebankan sepenuhnya kepada penjual.

Biaya logistik perusahaan e-commerce dibebankan kepada seller. Hal ini dapat membuat nilai keuntungan yang kecil meskipun memiliki nilai sales atau penjualan yang besar akibat biaya logistik

PROBLEM STATEMENT

Tujuan :

1. Mengetahui apakah terdapat pengaruh logistik terhadap keuntungan penjualan suatu produk tertentu
2. Mengetahui faktor lain yang mempengaruhi keuntungan penjualan produk
3. Melakukan analisa untuk mengetahui kategori barang dan kota asal pembeli yang memiliki keuntungan terbesar dan terkecil

2. Data Understanding

Data Understanding

Tools Yang DIgunakan : SQL

Sumber = Kaggle (https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce/data?select=olist_orders_dataset.csv)
Nama = Brazilian E-Commerce Public Dataset by Olist
Format = csv
Tujuan = Analisa Keuntungan Perusahaan Berdasarkan Produk, Kota Pembeli, Biaya Logistik, dan Durasi Pengiriman

Tabel Yang Digunakan :
olist_customers_dataset
product_category_name_translation
olist_products_dataset
olist_orders_dataset
olist_order_payments_dataset
olist_order_items_dataset

Data Exploration olist_customers_dataset

```sql
select count(*)
from olist_customers_dataset;
```

	123 count
1	99,441

Column Name	#	Data type
A-Z customer_id	1	varchar(50)
A-Z customer_unique_id	2	varchar(50)
123 customer_zip_code_prefix	3	int4
A-Z customer_city	4	varchar(50)
A-Z customer_state	5	varchar(50)

- Terdapat 99441 baris dan 5 kolom
- customer_id sebagai primary key
- Empat Kolom memiliki tipe data varchar yaitu : customer_id, customer_unique_id, customer_city, dan customer_state
- Satu Kolom memiliki tipe data integer yaitu : customer_zip_code_prefix
- Ukuran, struktur, dan tipe data tabel olist_customers_dataset sudah benar

Data Exploration product_category_name_translation

```
select count(*)
from product_category_name_translation;
```

	123 count
1	74

Column Name	#	Data type
A-Z product_category_name	1	varchar(50)
A-Z product_category_name_english	2	varchar(50)

- Terdapat 74 baris dan 2 kolom
- product_category_name sebagai primary key
- Empat Kolom memiliki tipe data varchar yaitu : product_category_name dan product_category_name_english
- Ukuran, struktur, dan tipe data tabel product_category_name_translation sudah benar

Data Exploration olist_products_dataset

```
select count(*)
from olist_products_dataset;
```

	123 count
1	32,951

Column Name	#	Data type
A-Z product_id	1	varchar(50)
A-Z product_category_name	2	varchar(50)
123 product_name_lenght	3	int4
123 product_description_lenght	4	int4
123 product_photos_qty	5	int4
123 product_weight_g	6	int4
123 product_length_cm	7	int4
123 product_height_cm	8	int4
123 product_width_cm	9	int4

- Terdapat 32951 baris dan 9 kolom
- olist_products_dataset memiliki product_id sebagai primary key dan product_category_name sebagai foreign key
- Dua kolom memiliki tipe data varchar yaitu : product_id dan product_category_name
- Tujuh kolom memiliki tipe data integer yaitu : product_name_length, product_description_lenght, product_photos_qty, product_weight_g, product_length_cm, product_height_cm, dan product_width_cm
- Ukuran, struktur, dan tipe data tabel olist_products_dataset sudah benar

Data Exploration olist_orders_dataset

```
select count(*)
from olist_orders_dataset ;
```

	123 count
1	99,441

Column Name	#	Data type
A-Z order_id	1	varchar(50)
A-Z customer_id	2	varchar(50)
A-Z order_status	3	varchar(50)
A-Z order_purchase_timestamp	4	varchar(50)
A-Z order_approved_at	5	varchar(50)
A-Z order_delivered_carrier_date	6	varchar(50)
A-Z order_delivered_customer_date	7	varchar(50)
A-Z order_estimated_delivery_date	8	varchar(50)

- Terdapat 99441 baris dan 8 kolom
- order_id sebagai primary key dan customer_id sebagai foreign key
- Semua kolom memiliki tipe data varchar
- Ukuran dan struktur tabel olist_orders_dataset sudah benar
- Tipe data pada kolom order_purchase_timestamp, order_approved_at, order_delivered_carrier_date, order_delivered_customer_date dan order_estimated_delivery_date kurang tepat. Lebih baik diganti menjadi timestamp

Data Exploration olist_order_payments_dataset

```
select count (*)
from olist_order_payments_dataset ;
```

	123 count
1	103,886

Column Name	#	Data type
A-Z order_id	1	varchar(50)
123 payment_sequential	2	int4
A-Z payment_type	3	varchar(50)
123 payment_installments	4	int4
123 payment_value	5	float4
A-Z payment_unique	6	varchar(200)

- Terdapat 103886 baris dan 5 kolom
- payment_unique sebagai primary key dan order_id sebagai foreign key
- Tiga kolom memiliki tipe data varchar yaitu : order_id, payment_type, dan payment_unique
- Dua kolom memiliki tipe data integer yaitu : payment_sequential dan payment_installments
- Satu kolom memiliki tipe data float yaitu : payment_value
- Ukuran, struktur, dan tipe data tabel olist_order_payments_dataset sudah benar

Data Exploration olist_order_items_dataset

```
select count(*)
from olist_order_items_dataset;
```

	123 count
1	112,650

Column Name	#	Data type
A-Z order_id	1	varchar(50)
123 order_item_id	2	int4
A-Z product_id	3	varchar(50)
A-Z seller_id	4	varchar(50)
A-Z shipping_limit_date	5	varchar(50)
123 price	6	float4
123 freight_value	7	float4
A-Z item_unique	8	varchar(200)

- Terdapat 112650 baris dan 7 kolom
- item_unique sebagai primary key
- order_id dan product_id sebagai foreign key
- Lima kolom memiliki tipe data varchar yaitu : order_id, product_id, seller_id, shipping_limit_date, dan item_unique
- Satu kolom memiliki tipe data integer yaitu : order_item_id
- Dua kolom memiliki tipe data float yaitu : price dan freight_value
- Ukuran dan struktur tabel olist_order_items_dataset sudah benar
- Tipe data pada kolom shipping_limit_date kurang tepat. Lebih baik diganti menjadi timestamp

Data Exploration

Missing Value tabel olist_customers_dataset

	nama_kolom	jumlah_missing	persentase_missing
1	customer_unique_id	0	0
2	customer_zip_code_prefix	0	0
3	customer_city	0	0
4	customer_state	0	0
5	customer_id	0	0

Berdasarkan hasil output, tidak terdapat missing value pada tabel olist_customers_dataset

Data Exploration

Missing Value tabel product_category_name_translation

	nama_kolom	jumlah_missing	persentase_missing
1	product_category_name	0	0
2	product_category_name_er	0	0

Berdasarkan hasil output, tidak terdapat missing value pada tabel product_category_name_translation

Data Exploration

Missing Value tabel olist_products_dataset

	nama_kolom	jumlah_missing	persentase_missing
1	product_category_name	610	1.85
2	product_name_lenght	610	1.85
3	product_description_lenght	610	1.85
4	product_photos_qty	610	1.85
5	product_weight_g	6	0.02
6	product_length_cm	2	0.01
7	product_height_cm	2	0.01
8	product_width_cm	2	0.01
9	product_id	0	0

Berdasarkan hasil output :
Terdapat missing value pada tabel olist_products_dataset

- Missing value pada kolom product_category_name berjumlah 610 baris (1,85%)
- Missing value pada kolom product_name_length berjumlah 610 baris (1,85%)
- Missing value pada kolom product_description_lenght berjumlah 610 baris (1,85%)
- Missing value pada kolom product_photos_qty berjumlah 610 baris (1,85%)
- Missing value pada kolom product_weight_g berjumlah 6 baris (0,01%)
- Missing value pada kolom product_length_cm berjumlah 2 baris (0,01%)
- Missing value pada kolom product_height_cm berjumlah 2 baris (0,01%)
- Missing value pada kolom product_width_cm berjumlah 2 baris (0,01%)

Data Exploration

Missing Value tabel olist_orders_dataset

	nama_kolom	jumlah_missing	persentase_missing
1	customer_id	0	0
2	order_status	0	0
3	order_purchase_timestamp	0	0
4	order_approved_at	160	0.16
5	order_delivered_carrier_date	1,783	1.79
6	order_delivered_customer_date	2,965	2.98
7	order_estimated_delivery_date	0	0
8	order_id	0	0

Berdasarkan hasil output :

- Missing value pada kolom order_approved_at berjumlah 160 baris (0,16%)
- Missing value pada kolom order_delivered_carrier_date berjumlah 1783 baris (1,79%)
- Missing value pada kolom order_delivered_customer_date berjumlah 2965 baris (2,98%)

Data Exploration

Missing Value tabel olist_order_payments_dataset

	A-Z nama_kolom	123 jumlah_missing	123 persentase_missing
1	order_id	0	0
2	payment_sequential	0	0
3	payment_type	0	0
4	payment_installments	0	0
5	payment_value	0	0
6	payment_unique	0	0

Berdasarkan hasil output, tidak terdapat missing value pada tabel olist_order_payments_dataset

Data Exploration

Missing Value tabel olist_order_items_dataset

	nama_kolom	jumlah_missing	persentase_missing
1	order_item_id	0	0
2	product_id	0	0
3	seller_id	0	0
4	price	0	0
5	freight_value	383	0.34
6	order_id	0	0
7	shipping_limit_date	0	0

Berdasarkan hasil output :

- Terdapat missing value pada tabel olist_order_items_dataset
- Missing value pada kolom freight_value berjumlah 383 baris (0,34%)

Data Exploration
Duplicate Value tabel olist_customers_dataset

```
with duplikat as (
    select
        (select count(*) from olist_customers_dataset) as jumlah_seluruh,
        (select count(*) from olist_customers_dataset) -
        (select count(*) from (select distinct * from olist_customers_dataset)) as jumlah_duplicate)
select jumlah_duplicate, (jumlah_duplicate/jumlah_seluruh*100) as persentase_duplicate
from duplikat;
```

	123 jumlah_duplicate	123 persentase_duplicate
1	0	0

Berdasarkan hasil output, tidak terdapat duplicate value pada tabel olist_customers_dataset

Data Exploration

Duplicate Value tabel product_category_name_translation

```
with duplikat as (
    select
        (select count(*) from product_category_name_translation) as jumlah_seluruh,
        (select count(*) from product_category_name_translation) -
        (select count(*) from (select distinct * from product_category_name_translation)) as jumlah_duplicate)
select
    jumlah_duplicate,
    round(((jumlah_duplicate*100/jumlah_seluruh)::numeric), 2) as persentase_duplicate
from duplikat;
```

	123 jumlah_duplicate	123 persentase_duplicate
1	0	0

Berdasarkan hasil output, tidak terdapat duplicate value pada tabel product_category_name_translation

Data Exploration
Duplicate Value tabel olist_products_dataset

```
with duplikat as (
    select
        (select count(*) from olist_products_dataset) as jumlah_seluruh,
        (select count(*) from olist_products_dataset) -
        (select count(*) from (select distinct * from olist_products_dataset)) as jumlah_duplicate
)
select jumlah_duplicate, (jumlah_duplicate*100/jumlah_seluruh) as persentase_duplicate
from duplikat;
```

	123 jumlah_duplicate	123 persentase_duplicate
1	0	0

Berdasarkan hasil output, tidak terdapat duplicate value pada tabel olist_products_dataset

Data Exploration
Duplicate Value tabel olist_orders_dataset

```sql
with duplikat as (
    select
        (select count(*) from olist_orders_dataset) as jumlah_seluruh,
        (select count(*) from olist_orders_dataset) -
        (select count(*) from (select distinct * from olist_orders_dataset)) as jumlah_duplicate
)
select jumlah_duplicate, (jumlah_duplicate*100/jumlah_seluruh) as persentase_duplicate
from duplikat;
```

	123 jumlah_duplicate	123 persentase_duplicate
1	0	0

Berdasarkan hasil output, tidak terdapat duplicate value pada tabel olist_orders_dataset

Data Exploration

Duplicate Value tabel olist_order_payments_dataset

```sql
with duplikat as (
    select
        (select count(*) from olist_order_payments_dataset) as jumlah_seluruh,
        (select count(*) from olist_order_payments_dataset) -
        (select count(*) from(select distinct * from olist_order_payments_dataset)) as jumlah_duplicate
)
select jumlah_duplicate, (jumlah_duplicate/jumlah_seluruh*100) as persentase_duplicate
from duplikat;
```

	123 jumlah_duplicate	123 persentase_duplicate
1	0	0

Berdasarkan hasil output, tidak terdapat duplicate value pada tabel olist_order_payments_dataset

Data Exploration
Duplicate Value tabel olist_order_items_dataset

```
with duplikat as (
    select
        (select count(*) from olist_order_items_dataset) as jumlah_seluruh,
        (select count(*) from olist_order_items_dataset) -
        (select count(*) from(select distinct * from olist_order_items_dataset)) as jumlah_duplicate
)
select jumlah_duplicate, (jumlah_duplicate/jumlah_seluruh*100) as persentase_duplicate
from duplikat;
```

	123 jumlah_duplicate	123 persentase_duplicate
1	0	0

Berdasarkan hasil output, tidak terdapat duplicate value pada tabel olist_order_items_dataset

Data Exploration

Outlier tabel olist_customers_dataset Kolom customer_zip_code_prefix

```sql
with kuantil as (
    select
        PERCENTILE_CONT(0.25) within group (order by customer_zip_code_prefix) as q1,
        PERCENTILE_CONT(0.75) within group (order by customer_zip_code_prefix) as q3
    from olist_customers_dataset
),
outlier as (
    select
        (q3 + (1.5*(q3-q1))) as upper_bound,
        (q1 - (1.5*(q3-q1))) as lower_bound
    from kuantil
),
outlier_sum as (
    select
        count (*) as jumlah_outlier
    from olist_customers_dataset ocd
    cross join outlier
    where (ocd.customer_zip_code_prefix > upper_bound) or (ocd.customer_zip_code_prefix < lower_bound)
)
select
    os.jumlah_outlier,
    round((os.jumlah_outlier*100/(select count(*) from olist_customers_dataset)::numeric), 2) as persentase_outlier
from outlier_sum os;
```

	123 jumlah_outlier	123 persentase_outlier
1	0	0

Berdasarkan hasil output, tidak terdapat outlier pada tabel olist_customers_dataset pada kolom customer_zip_code_prefix

Data Exploration

Outlier tabel olist_products_dataset

Seluruh kolom dengan tipe data integer

	123 jumlah_outlier	123 persentase_outlier
1	290	0.88

Kolom product_name_lenght memiliki outlier sebanyak 290 baris (0,88%)

	123 jumlah_outlier	123 persentase_outlier
1	2,078	6.31

Kolom product_description_lenght memiliki outlier sebanyak 2078 baris (6,31%)

	123 jumlah_outlier	123 persentase_outlier
1	849	2.58

Kolom product_photos_qty memiliki outlier sebanyak 849 baris (2,58%)

Data Exploration

Outlier tabel olist_products_dataset

Seluruh kolom dengan tipe data integer

	jumlah_outlier	persentase_outlier
1	4,551	13.81

Kolom product_weight_g memiliki outlier sebanyak 4551 baris (13,81%)

	jumlah_outlier	persentase_outlier
1	1,380	4.19

Kolom product_length_cm memiliki outlier sebanyak 1380 baris (4,19%)

	jumlah_outlier	persentase_outlier
1	1,892	5.74

Kolom product_height_cm memiliki outlier sebanyak 1892 baris (5,74%)

Data Exploration

Outlier tabel olist_products_dataset
Seluruh kolom dengan tipe data integer

	123 jumlah_outlier	123 persentase_outlier
1	912	2.77

Kolom product_width_cm memiliki outlier sebanyak 912 baris (2,77%)

Data Exploration

Outlier tabel olist_order_payments_dataset
Seluruh kolom dengan tipe data integer

	123 jumlah_outlier	123 persentase_outlier
1	4,526	4.36

Kolom payment_sequential memiliki outlier sebanyak 4526 baris (4,36%)

	123 jumlah_outlier	123 persentase_outlier
1	6,313	6.08

Kolom payment_installments memiliki outlier sebanyak 6313 baris (6,08%)

	123 jumlah_outlier	123 persentase_outlier
1	7,981	7.68

Kolom payment_value memiliki outlier sebanyak 7981 baris (7,68%)

Data Exploration

Outlier tabel olist_order_items_dataset

Seluruh kolom dengan tipe data integer

	jumlah_outlier	persentase_outlier
1	13,984	12.41

Kolom order_item_id memiliki outlier sebanyak 13984 baris (12,41%)

	jumlah_outlier	persentase_outlier
1	8,427	7.48

Kolom price memiliki outlier sebanyak 8427 baris (7,48%)

	jumlah_outlier	persentase_outlier
1	12,134	10.77

Kolom freight_value memiliki outlier sebanyak 12134 baris (10,77%)

Insight Data Exploration

- Tidak terdapat duplicate value pada semua tabel
- Tipe data pada tabel olist_orders_dataset kolom order_purchase_timestamp, order_approved_at, order_delivered_carrier_date, order_delivered_customer_date dan order_estimated_delivery_date kurang tepat. Lebih baik diganti menjadi timestamp
- Tipe data pada tabel olist_order_items_dataset kolom shipping_limit_date kurang tepat. Lebih baik diganti menjadi timestamp
- Terdapat missing value pada tabel olist_products_dataset berjumlah :
- kolom product_name_length berjumlah 610 baris (1,85%)
- kolom product_description_lenght berjumlah 610 baris (1,85%)
- kolom product_photos_qty berjumlah 610 baris (1,85%)
- kolom product_weight_g berjumlah 6 baris (0,01%)
- kolom product_length_cm berjumlah 2 baris (0,01%)
- kolom product_height_cm berjumlah 2 baris (0,01%)
- kolom product_width_cm berjumlah 2 baris (0,01%)
- Terdapat missing value pada tabel olist_order_items_dataset berjumlah :
- kolom freight_value berjumlah 383 baris (0,34%)
- Terdapat outlier pada semua kolom yang memiliki tipe data numerik pada setiap tabel, kecuali kolom customer_zip_code_prefix pada tabel olist_customers_dataset

Insight Data Exploration

- Terdapat missing value pada tabel olist_orders_dataset
- Missing value pada kolom order_approved_at berjumlah 160 baris (0,16%)
- Missing value pada kolom order_delivered_carrier_date berjumlah 1783 baris (1,79%)
- Missing value pada kolom order_delivered_customer_date berjumlah 2965 baris (2,98%)

3. Data Preparation

Data Cleaning

Penanganan Missing Value

Penanganan missing value pada tabel olist_products_dataset

```
update olist_products_dataset
set product_category_name = 'Unknown'
where product_category_name is null or product_category_name = '';
```

Penanganan mising value pada tabel olist_products_dataset dengan kolom product_category_name diisi dengan "Unknown"

Data Cleaning
Penanganan Missing Value

Penanganan missing value pada tabel olist_products_dataset

```
update olist_products_dataset
set product_name_lenght = (select
                             PERCENTILE_CONT(0.50) within group (order by product_name_lenght)
                           from olist_products_dataset)
where product_name_lenght is null or product_name_lenght = 0;

update olist_products_dataset
set product_description_lenght = (select
                                    PERCENTILE_CONT(0.50) within group (order by product_description_lenght)
                                  from olist_products_dataset)
where product_description_lenght is null or product_description_lenght = 0;
```

- Penanganan mising value pada tabel olist_products_dataset dengan kolom product_name_lenght, product_description_lenght, product_photos_qty, product_weight_g, product_length_cm, product_height_cm, product_width_cm
- Berupa diisi dengan median.
- Alasannya adalah kolom dengan missing value memiliki outlier/nilai ekstrim. Sehingga apabila menggunakan mean, dapat menyebabkan pergeseran nilai tengah.

Data Cleaning

Penanganan Missing Value

Penanganan missing value pada tabel olist_orders_dataset

```
update olist_orders_dataset
set order_approved_at = order_purchase_timestamp
where order_approved_at is null or order_approved_at = '';

update olist_orders_dataset
set order_delivered_carrier_date = order_purchase_timestamp
where order_delivered_carrier_date is null or order_delivered_carrier_date = '';

update olist_orders_dataset
set order_delivered_customer_date = order_purchase_timestamp
where order_delivered_customer_date is null or order_delivered_customer_date = '';
```

- Penanganan mising value pada tabel olist_orders_dataset dengan kolom order_approved_at, order_delivered_carrier_date, dan order_delivered_customer_date dengan cara diisi dengan tanggal yang ada pada kolom order_purchase_timestamp.
- Alasannya adalah untuk dapat merubah tipe data menjadi timestamp, tidak diperbolehkan terdapat missing value atau isi selain format tanggal.
- Kolom order_purchase_timestamp dipilih sebagai tanggal untuk missing value karena untuk menyesuaikan tanggal pemesanan.

Data Cleaning

Penanganan Tipe Data

Penaganan tipe data pada tabel olist_orders_dataset dan tabel olist_order_items_dataset

```sql
alter table olist_orders_dataset
alter column order_purchase_timestamp type timestamp
USING order_purchase_timestamp::timestamp without time zone;
alter table olist_orders_dataset
alter column order_approved_at type timestamp
USING order_approved_at::timestamp without time zone;

alter table olist_orders_dataset
alter column order_delivered_carrier_date type timestamp
USING order_delivered_carrier_date::timestamp without time zone;

alter table olist_orders_dataset
alter column order_delivered_customer_date type timestamp
USING order_delivered_customer_date::timestamp without time zone;

alter table olist_orders_dataset
alter column order_estimated_delivery_date type timestamp
USING order_estimated_delivery_date::timestamp without time zone;

alter table olist_order_items_dataset
alter column shipping_limit_date type timestamp
USING shipping_limit_date::timestamp without time zone;
```

Penanganan tipe data pada
tabel olist_orders_dataset
kolom
order_purchase_timestamp
order_approved_at
order_delivered_carrier_date
order_delivered_customer_date
order_estimated_delivery_date
tabel olist_order_items_dataset
kolom shipping_limit_date
dengan cara merubah tipe data menjadi timestamp

Data Cleaning

Memeriksa kembali missing value setelah penanganan

	nama_kolom	jumlah_missing	persentase_missing
1	product_category_name	0	0
2	product_name_lenght	0	0
3	product_description_lenght	0	0
4	product_photos_qty	0	0
5	product_weight_g	0	0
6	product_length_cm	0	0
7	product_height_cm	0	0
8	product_width_cm	0	0
9	product_id	0	0

	nama_kolom	jumlah_missing	persentase_missing
1	freight_value	0	0

Missing value berhasil ditangani

Data Cleaning

Memeriksa kembali missing value setelah penanganan

	nama_kolom	jumlah_missing	persentase_missing
1	customer_id	0	0
2	order_status	0	0
3	order_id	0	0
4	order_purchase_timestamp	0	0
5	order_approved_at	0	0
6	order_delivered_carrier_date	0	0
7	order_delivered_customer_date	0	0
8	order_estimated_delivery_date	0	0

Missing value berhasil ditangani

Data Cleaning
Penanganan Duplicate Value

Tidak terdapat duplicate value pada seluruh tabel. Tidak ada penanganan

Data Cleaning
Penanganan Outlier

Penanganan outlier berupa mengkonfirmasi kembali datanya kepada pemberi data. Apakah datanya valid atau tidak

Apabila pemberi data menyatakan bahwa data yang berupa outlier adalah valid, maka tidak ada penanganan outlier

Data Cleaning
Feature Engineering

```
alter table olist_orders_dataset
add column durasi_hari_pengiriman int;

update olist_orders_dataset
set durasi_hari_pengiriman = order_estimated_delivery_date::date - order_purchase_timestamp::date
where durasi_hari_pengiriman is null;
```

Membuat kolom baru bernama durasi_hari_pengiriman untuk mengetahui berapa lama waktu pengiriman

4. EDA

Kategori barang dengan keuntungan terbesar

	nama_kategori_barang	jumlah_transaksi	total_sales	total_biaya_kurir	keuntungan	ranking
1	computers_accessories	8,082	1,585,340	153,180	489,899	1
2	furniture_decor	8,744	1,430,180	183,174	481,923	2
3	bed_bath_table	11,823	1,712,550	217,878	402,172	3
4	office_furniture	1,778	646,827	71,478.8	289,191.2	4
5	housewares	7,355	1,094,760	154,264	273,907	5

- Kategori computers_accessories memberikan keuntungan yang paling besar dibandingkan kategori lain meskipun jumlah sales yang lebih kecil
- Kategori seperti bed_bath_table memiliki sales yang lebih besar dibandingkan computers_accessories. Hal ini dapat terjadi akibat biaya kurir yang lebih mahal
- Dianjurkan untuk mencari mitra logistik yang memiliki biaya pengiriman yang lebih murah sehingga keuntungan lebih besar
- Dianjurkan untuk melakukan marketing campaign pada platform social media untuk kategori barang dengan jumlah transaksi yang masih rendah seperti office_furniture

Kategori barang dengan keuntungan terbesar berdasarkan kota asal pelanggan

	nama_kategori_barang	kota	durasi_hari_pengiriman	jumlah_transaksi	total_sales	total_biaya_kurir	keuntungan	ranking
1	computers_accessories	sao paulo	21.47	1,251	287,322	16,952.8	124,182.2	1
2	fixed_telephony	rio de janeiro	30	24	112,491	515.32	96,184.78	2
3	bed_bath_table	sao paulo	20.38	2,146	284,304	31,430	72,420	3
4	furniture_decor	sao paulo	20.27	1,366	194,304	21,217.4	65,632.6	4
5	health_beauty	sao paulo	17.77	1,805	265,146	23,399.4	46,713.6	5
6	office_furniture	sao paulo	24.25	246	93,509.5	6,869.61	43,378.89	6
7	auto	goiania	27.05	40	48,975	722.03	43,169.13	7
8	office_furniture	rio de janeiro	35.07	244	84,009.9	9,296.7	38,904.7	8
9	furniture_decor	rio de janeiro	29	653	103,240	13,924.4	31,853.3	9
10	housewares	sao paulo	17.97	1,407	167,211	21,827.2	31,372.8	10

- Kategori computers_accessories sebagai kategori dengan keuntungan yang paling besar, transaksi terjadi di kota sao paula
- Penjualan kategori selain computers_accessories, mayoritas pelangggan berasal dari kota sao paula
- Durasi pengiriman ke sao paula relatif cepat jika dibandingkan kota lain seperti goiania dan rio de janeiro
- Sehingga dapat disarankan untuk mencari mitra logistik di kota goiania dan rio de janeiro

Kategori barang dengan keuntungan terkecil

	nama_kategori_barang	kota	durasi_hari_pengiriman	jumlah_transaksi	total_sales	total_biaya_kurir	total_modal	keuntungan	ranking
1	garden_tools	cuiaba	30.19	47	5,749.18	2,502.28	14,812.1	-11,565.2	1
2	musical_instruments	sao paulo	17.31	121	26,396.7	2,019.94	34,865.1	-10,488.34	2
3	agro_industry_and_commerce	atibaia	22.72	25	1,787.1	674	9,907.5	-8,794.4	3
4	computers_accessories	caxias do sul	28.81	31	4,218.79	1,026.37	11,753.3	-8,560.88	4
5	home_appliances_2	palmas	28	14	529.55	1,393.84	6,019.86	-6,884.15	5
6	baby	natal	28.31	13	1,763.86	442.99	7,475.13	-6,154.26	6
7	sports_leisure	niteroi	23.61	84	10,442.6	2,259.3	12,952	-4,768.7	7
8	watches_gifts	goiania	26.52	60	14,086	1,168.9	17,413.2	-4,496.1	8
9	garden_tools	guarulhos	22.43	76	5,585.01	1,361.54	8,671.55	-4,448.08	9
10	small_appliances	brasilia	28	24	12,247.9	1,006.5	15,436.1	-4,194.7	10

- Masih terdapat kategori barang yang mengalami kerugian. Hal ini terjadi akibat modal dan biaya kurir yang lebih besar dibandingkan penjualan
- Dianjurkan untuk meninjau ulang harga barang dan diskon agar tidak menjual barang lebih rendah dari modal dan biaya pengiriman

Jumlah setiap kategori transaksi

	kategori_transaksi	jumlah_kategori_transaksi
1	Sedang	51,952
2	Besar	25,972
3	Kecil	25,962

- Mayoritas transaksi berupa kategori sedang
- Dianjurkan untuk meninjau ulang harga barang dan diskon sehingga dapat meningkatkan transaksi berkategori besar

5. Insight

Insight

- Kategori computers_accessories memberikan keuntungan yang paling besar dibandingkan kategori lain meskipun jumlah sales yang lebih kecil
- Kategori seperti bed_bath_table memiliki sales yang lebih besar dibandingkan computers_accessories. Hal ini dapat terjadi akibat biaya kurir yang lebih mahal
- Kategori computers_accessories sebagai kategori dengan keuntungan yang paling besar, transaksi terjadi di kota sao paula
- Penjualan kategori selain computers_accessories, mayoritas pelangggan berasal dari kota sao paula
- Durasi pengiriman ke sao paula relatif cepat jika dibandingkan kota lain seperti goiania dan rio de janeiro
- Masih terdapat kategori barang yang mengalami kerugian. Hal ini terjadi akibat modal dan biaya kurir yang lebih besar dibandingkan penjualan
- Mayoritas transaksi berupa kategori sedang

6. Recommendation

Recommendation

- Dianjurkan untuk mencari mitra logistik yang memiliki biaya pengiriman yang lebih murah sehingga keuntungan lebih besar
- Dianjurkan untuk melakukan marketing campaign pada platform social media untuk kategori barang dengan jumlah transaksi yang masih rendah seperti office_furniture sehingga mendapat atensi dari pelanggan online dan meningkatkan penjualan
- Dapat disarankan untuk mencari mitra logistik di kota goiania dan rio de janeiro untuk mempercepat pengiriman dan menghemat biaya pengiriman
- Dianjurkan untuk meninjau ulang harga barang dan diskon agar tidak menjual barang lebih rendah dari modal dan biaya pengiriman, serta meningkatkan transaksi berkategori besar

Terima Kasih